第1章 绪论

本章是全书的引论，建立后续各章的共同语言。考试常考：

- 机器学习的定义与基本设定
- 分类、回归、聚类
- 泛化能力
- 归纳偏好（含奥卡姆剃刀、没有免费的午餐）

一、什么是机器学习

机器学习：从**数据**中学习**规律**，使计算机在某一**任务**上的**性能**随**经验**增加而提升。
西瓜书采用 Mitchell 的经典定义：一个计算机程序在任务 T 上、用性能度量 P 衡量，若其性能随经验 E 而提高，则称该程序在**学习**。
记作三元组：

$$\text{学习} \Leftrightarrow \langle T, P, E \rangle$$

符号	含义	例
T	任务	识别西瓜是否成熟
P	性能度量	分类准确率
E	经验	训练样本（含标记或不含标记）

与“显式编程”的区别：传统程序由人写死规则；机器学习由**数据驱动**自动归纳规则/模型参数。
典型流程：

```
收集数据 → 特征表示 → 选择模型/算法 → 训练（学习）→ 评估 → 部署预测
```

二、学习任务与预测目标概览

按训练样本是否带标记、预测目标形式，常见任务如下。

类型	训练数据	目标	典型算法（后文会学）
分类	有标记	离散类别	决策树、Logistic、SVM、神经网络
回归	有标记	连续数值	线性回归、神经网络
聚类	无标记	发现簇结构	k-均值、密度聚类

1. 分类（Classification）

定义：预测样本属于哪一个**离散类别**（标签 $y \in \{c_1, c_2, \ldots, c_K\}$）。

- **二分类**：$K = 2$，如“好瓜 / 坏瓜”“spam / 非 spam”
- **多分类**：$K > 2$，如手写数字 0～9

输出可以是**类别**或**属于各类的概率**（如 Logistic 输出 $P(y = 1|x)$）。
评价：准确率、查准率/查全率/F1、ROC-AUC 等（见第2章）。

2. 回归（Regression）

定义：预测样本的**连续实值**输出 $y \in \mathbb{R}$。
例：预测西瓜含糖量、房价、温度。
与分类的区别：y 可比较大小、有距离意义；常用**均方误差 MSE** 等度量（见第2、3章）。

3. 聚类（Clustering）

定义：无标记数据，将样本划分为若干簇，使**簇内相似、簇间相异**。
例：客户分群、文档主题发现。
与分类的区别：训练阶段**没有**给定类别标签，簇的语义往往由人事后解释；属于**无监督学习**。

4. 其他常见设定（了解即可）

- **半监督学习**：少量有标记 + 大量无标记
- **强化学习**：智能体通过与环境交互、获得奖励信号来学习策略
- **密度估计、降维等**：也属于无监督或广义学习问题

三、泛化能力

泛化能力（Generalization）：学得的模型对**未见过的样本**（新数据、测试集）表现良好的能力。
这是机器学习的**根本目标**：

- 训练集上表现好 $\neq$ 学好了（可能**过拟合**，见第2章）
- 真正关心的是模型在**分布外/新样本**上的误差，即**泛化误差** E_{gen}

关系（第2章会展开）：

误差	含义	能否直接算
训练误差	训练集上的表现	能
泛化误差	全体可能样本上的表现	不能直接算，用测试集估计

核心矛盾：只有有限训练数据，却要推断普遍规律 → 必然依赖**假设与偏好**（下一节）。

四、归纳偏好

1. 为什么需要归纳偏好?

同一训练集上，往往有**无穷多个**假设与数据一致；若不对“什么样的假设更好”做先验假设，就无法从众多假设中做出确定选择。
归纳偏好（Inductive Bias）：学习算法在假设空间中对某类假设的**隐性倾向**；或等价地，任何有效学习算法都必须依赖某种与任务无关的**先验假设**。
不同算法 = 不同假设空间 + 不同归纳偏好。

算法	归纳偏好（直观）
决策树	更偏好短树、划分少的树
神经网络	更偏好光滑、层次化的表示
线性模型	更偏好线性可分边界

2. 奥卡姆剃刀（Occam's Razor）

思想：若无必要，勿增实体——在多个假设与训练数据一致时，优先选**更简单**的假设。

- 决策树剪枝、正则化（L_1/L_2）都可看作“简单性”偏好的体现

- 注意：“简单”需与具体表示挂钩，并非绝对唯一标准

3. 没有免费的午餐定理（No Free Lunch, NFL）

结论：在所有可能的问题分布上，**任意两种学习算法的期望性能相同**。
含义：

- 不存在**放之四海而皆准**的最优算法
- 算法优劣必须结合**具体问题**、数据分布、特征与任务来谈
- 实践中的成功来自：归纳偏好与**当前问题**相匹配

考试一句话：NFL 说明“必须针对具体问题选模型/算法”，不能脱离数据谈万能学习器。

4. 与第2章的衔接

- **经验误差 vs 泛化误差**、过拟合：泛化能力不足的表现
- **偏差-方差分解**：不同归纳偏好导致不同的偏差/方差权衡
- **模型选择、比较检验**：在有限数据下判断哪种偏好更合适

本章知识框架

```
绪论
├── 机器学习定义〈T,P,E〉
├── 任务概览
│   ├── 分类（有标记，离散输出）
│   ├── 回归（有标记，连续输出）
│   └── 聚类（无标记，分簇）
├── 泛化能力（根本目标）
└── 归纳偏好
    ├── 假设空间与一致性
    ├── 奥卡姆剃刀
    └── 没有免费的午餐
```

期末考试重点等级

★★★★★（必考）

- 机器学习定义 $\langle T, P, E \rangle$

- 分类、回归、聚类的区别
- 泛化能力的含义
- 归纳偏好是什么；奥卡姆剃刀；NFL 定理结论

★★★★

- 监督 vs 无监督（聚类）
- 训练误差与泛化误差的关系（概念层面）

★★★

- 半监督、强化学习等扩展设定

第 2 章 模型选择与评估

- 训练误差与泛化误差
- 过拟合与欠拟合
- 数据集划分方法
- 性能度量指标
- 偏差与方差
- 比较检验方法

一、经验误差与泛化误差

1. 错误率

分类错误样本占总样本比例：

$$E = \frac{a}{m}$$

其中：

- a：分类错误样本数

- m：总样本数

---

2. 精度（Accuracy）

$$\text{Accuracy} = 1 - E$$

即：

$$\text{Accuracy} = \frac{m - a}{m}$$

---

3. 经验误差（Training Error）

训练集上的误差：E_{train}
特点：

- 已知
- 容易计算

---

4. 泛化误差（Generalization Error）

模型在未知样本上的误差：E_{gen}
特点：

- 真正关心的指标
- 无法直接获得

核心思想

机器学习最终目标：不是让训练误差最小，而是让 E_{gen} 尽可能小。

二、过拟合与欠拟合

1. 欠拟合（Underfitting）

模型过于简单。表现：

- 训练误差大
- 测试误差大

例如：真实关系 $y = x^2$，却用直线拟合。

---

2. 过拟合（Overfitting）

模型过于复杂。表现：

- 训练误差很小
- 测试误差很大

原因：学习到了噪声。

---

3. 图像记忆

状态	训练误差	测试误差
欠拟合	高	高
合适	低	低
过拟合	极低	高

---

4. 解决过拟合

增加训练数据——最有效方法。

正则化

限制模型复杂度。例如 L_2 正则：

$$\lambda \|w\|^2$$

提前停止（Early Stopping）

训练过程中验证误差开始上升时停止。

三、评估方法

考试高频。

---

1. 留出法（Hold-Out）

数据集 D 划分为训练集、测试集。例如：70% 训练，30% 测试。
优点：简单。缺点：结果受随机划分影响大。

---

2. 交叉验证法（Cross Validation）

k折交叉验证

数据分成 k 份；每次 1 份测试、$k-1$ 份训练，循环 k 次，最终取平均值。
例：10 折交叉验证——第 1 折测试 … 第 10 折测试。
优点：结果稳定、利用数据充分。缺点：开销较大。

留一法（LOO）

特殊情况 $k=m$：每次 1 个样本测试、其余训练。
优点：训练集最大。缺点：计算量极大。

---

3. 自助法（Bootstrap）

有放回抽样，从 m 个样本中抽取 m 次。
某样本一次都没被抽到概率：

$$\left(1-\frac{1}{m}\right)^m$$

当 $m \to \infty$ 时，$e^{-1} \approx 0.368$。
Bootstrap 结论：约 63.2% 样本进入训练集，约 36.8% 样本作为测试集。
适用：数据量很小。

四、性能度量

1. 混淆矩阵

实际\预测	正例	反例
正例	TP	FN
反例	FP	TN

必须记住：

- **TP**（True Positive）：真正例
- **FP**（False Positive）：假正例
- **FN**（False Negative）：假反例
- **TN**（True Negative）：真反例

---

2. 查准率（Precision）

预测为正中有多少是真的正：

$$P = \frac{TP}{TP + FP}$$

---

3. 查全率（Recall）

真实正例中找出了多少：

$$R = \frac{TP}{TP + FN}$$

---

4. F1 值

Precision 和 Recall 调和平均：

$$F1 = \frac{2PR}{P + R}$$

等价形式：

$$F1 = \frac{2TP}{2TP + FP + FN}$$

考试高频。

五、PR 曲线

横轴：Recall；纵轴：Precision。特点：越靠右上越好。
平衡点（**BEP**）：满足 $P = R$ 的对应点。

六、ROC 曲线

考试重点。

---

1. 真正例率

$$\text{TPR} = \frac{TP}{TP + FN}$$

其实就是 Recall。

---

2. 假正例率

$$\text{FPR} = \frac{FP}{TN + FP}$$

---

3. ROC

横轴：FPR；纵轴：TPR。

---

4. 理想分类器

点 $(0, 1)$。

---

5. 随机猜测

直线 $y = x$。

七、AUC

ROC 曲线下面积：AUC。范围：$0.5 \sim 1$。
意义：随机取一个正例、一个反例，模型把正例排在前面的概率。

八、代价敏感错误率

现实中不同错误代价不同。例如癌症诊断：FN 远比 FP 严重。
代价矩阵：

	预测正	预测负
实际正	0	$Cost_{01}$
实际负	$Cost_{10}$	0

总成本：

$$\text{Cost} = FN \times Cost_{01} + FP \times Cost_{10}$$

九、比较检验

比较检验是一套统计学方法，用于判断：学习器之间的性能差异，究竟来自模型本身优劣，还是仅由测试数据随机划分、算法随机性带来的波动。
三个关键问题（对应本章主线）：

问题	对应内容
如何获得测试结果	评估方法
如何评估性能优劣	性能度量
如何判断实质差别	比较检验

---

1. 为什么不能直接比大小?

- **测试性能 ≠ 泛化性能**：测试集只是总体分布的一个样本，换一批测试数据，指标会波动。
- **算法有随机性**：随机初始化、随机森林抽样等，多次运行结果不同。
- **小样本下差异不可靠**：如 A 准确率 95%、B 为 94%，测试集仅 100 条，1% 的差距可能只是 1 条样本的差别，统计上可能**不显著**。

因此，不能仅凭一次测试结果直接断定“A 优于 B”，需要假设检验给出**把握度**。

---

2. 假设检验基础

原假设 H_0：两学习器性能无实质差异（或模型不优于基准）。
p 值：在 H_0 成立时，观测到当前结果（或更极端结果）的概率。

- 若 $p < \alpha$（常用 $\alpha = 0.05$），则**拒绝** H_0，认为差异在统计意义上显著。
- 论文中写 "$p < 0.05$，性能显著提升"，含义是：提升不太可能纯属偶然。

---

3. 单学习器 vs 固定基准

场景：分类准确率 60%，随机猜测为 50%，60% 是否真的优于瞎猜?
方法：二项检验 / 假设检验——计算在"瞎猜"前提下得到 60% 或更高准确率的概率；若 p 极小，说明模型确实有效。

---

4. 两学习器比较

（1）配对 t 检验（k 折交叉验证）

场景：k 折交叉验证得到 k 组结果，A、B 在**同一折**上成对比较。
设第 i 折性能差 $\Delta_i = \text{perf}_A^{(i)} - \text{perf}_B^{(i)}$，$\bar{\Delta} = \frac{1}{k}\sum_{i=1}^{k}\Delta_i$，$s$ 为 Δ_i 的标准差，则

$$t = \frac{|\bar{\Delta}|}{s/\sqrt{k}}$$

若 $|t| > t_{\alpha/2,\,k-1}$（查 t 分布临界值表），则认为两学习器性能有显著差异。
含义：检验"平均差是否显著偏离 0"，适用于**多组配对**的误差率/精度比较。

（2）McNemar 检验

场景：**同一测试集**上比较两个二分类器，关注预测不一致的样本。
列联表（e_{ij}：A 预测为 i、B 预测为 j，0=错/1=对）：

	B 对	**B 错**
A 对	e_{00}	e_{01}
A 错	e_{10}	e_{11}

仅利用不一致样本 e_{01}、e_{10}（A 对 B 错 / A 错 B 对）：

$$\tau_{\chi^2} = \frac{(|e_{01} - e_{10}| - 1)^2}{e_{01} + e_{10}}$$

$\alpha = 0.05$ 时临界值 **3.841**（χ^2 分布，自由度 1）。若 $\tau_{\chi^2} > 3.841$，拒绝“两学习器性能相同”的原假设。
适用：单测试集、二分类、比较逐样本预测差异。

（3）5×2 交叉验证 t 检验

西瓜书重点。流程：**2 折交叉验证，重复 5 次**，共 10 次训练/测试，兼顾数据利用与划分随机性。
第 i 次重复（$i = 1, \ldots, 5$）得到：

- 训练集上 A、B 误差差：$p_i^{(1)}, p_i^{(2)}$
- 测试集上 A、B 误差差：$q_i^{(1)}, q_i^{(2)}$

$$\bar{p} = \frac{1}{10} \sum_{i=1}^{5} \left(p_i^{(1)} + p_i^{(2)} \right), \quad \bar{q} = \frac{1}{10} \sum_{i=1}^{5} \left(q_i^{(1)} + q_i^{(2)} \right)$$

$$s_i^2 = \frac{\left(p_i^{(1)} - q_i^{(1)} \right)^2 + \left(p_i^{(2)} - q_i^{(2)} \right)^2}{2}$$

检验统计量：

$$\tau_t = \frac{\bar{q} - \bar{p}}{\sqrt{\frac{1}{5} \sum_{i=1}^{5} s_i^2}}$$

在 H_0（两学习器性能相同）下，τ_t 服从自由度为 5 的 t 分布。$\alpha = 0.1$ 时临界值约 **2.570**；超过临界值则认为差异显著。
优点：比单次留出法更稳，比留一法开销小；**考试常考**流程与公式含义。

---

5. 多个学习器比较

（1）Friedman 检验

场景：在**多个数据集**上比较 k 个学习器（如 A、B、C…）。
对每个数据集，将 k 个学习器按性能**排名**（1 为最好），再算各学习器的**平均秩** $\bar{r}_j$。

H_0：所有学习器性能相同。若 Friedman 统计量超过临界值，说明至少有两个学习器性能有显著差异。
类比：多学习器版的“方差分析（ANOVA）”，先看整体是否存在显著差别。

（2）Nemenyi 后续检验

Friedman 检验显著后，进一步判断哪两个学习器有显著差异。
临界差（CD）：平均秩之差若小于 CD，则认为两学习器性能无显著差异（常画临界差图）。
用途：多模型排序、选优；图上连线相连的学习器可视为“同一梯队”。

---

6. 方法选用小结

情形	常用方法
模型是否优于随机/基准	假设检验 / 二项检验
k 折结果，两模型成对比较	配对 t 检验
同一测试集，二分类两模型	McNemar 检验
重复 2 折×5 次，两模型	5×2 CV t 检验
多数据集、多学习器排序	Friedman + Nemenyi

十、偏差与方差（重点）

考试几乎必考概念题。

---

1. 偏差（Bias）

描述：预测平均值与真实值差距。偏差大 → 模型过于简单 → 欠拟合。

---

2. 方差（Variance）

描述：模型对训练数据变化的敏感程度。方差大 → 模型过于复杂 → 过拟合。

3. 噪声（Noise）

数据本身不可消除的随机性。

---

4. 偏差-方差分解

泛化误差：

$$E = \text{Bias}^2 + \text{Variance} + \text{Noise}$$

考试最爱问：

状态	Bias	Variance
欠拟合	高	低
过拟合	低	高

十一、本章知识框架（必背）

```
模型评估与选择
│
├── 经验误差
├── 泛化误差
│
├── 欠拟合
├── 过拟合
│
├── 数据划分
│    ├── 留出法
│    ├── k折交叉验证
│    ├── 留一法
│    └── Bootstrap
│
├── 性能度量
│    ├── Accuracy
│    ├── Precision
│    ├── Recall
```

```
│   ├── F1
│   ├── ROC
│   └── AUC
│
├── 代价敏感学习
│
├── 比较检验
│   ├── 假设检验（p值）
│   ├── 配对t检验
│   ├── McNemar检验
│   ├── 5×2CV t检验
│   └── Friedman / Nemenyi
│
└── 偏差-方差分解
```

期末考试重点等级

★★★★★（必须掌握）

- 过拟合与欠拟合
- 留出法、k折交叉验证、Bootstrap
- 混淆矩阵
- Precision、Recall、F1
- ROC与AUC
- 偏差-方差分解
- 比较检验思想；McNemar、5×2 CV t 检验

★★★★

- 配对 t 检验、假设检验与 p 值
- Friedman / Nemenyi（多学习器比较）
- 代价敏感错误率

★★★

- BEP
- 留一法的特点
- Bootstrap中36.8%的推导

第3章 线性模型

一、基本形式

线性模型（Linear Model）：
设样本

$$\mathbf{x} = (x_1, x_2, \cdots, x_d)^T$$

预测函数：

$$f(\mathbf{x}) = w_1 x_1 + w_2 x_2 + \cdots + w_d x_d + b$$

向量形式：

$$f(\mathbf{x}) = \mathbf{w}^T \mathbf{x} + b$$

其中：

- $\mathbf{w}$：权重向量
- b：偏置（截距）

线性模型的特点

优点：

- 形式简单
- 易于解释
- 计算效率高
- 许多复杂模型的基础

缺点：

- 表达能力有限
- 难以处理复杂非线性关系

二、线性回归（Linear Regression）

1. 问题描述

给定：

$$D = \{(x_i, y_i)\}_{i=1}^{m}$$

建立函数：

$$f(x) = wx + b$$

使预测值尽可能接近真实值。

---

2. 均方误差（MSE）

损失函数：

$$E(w, b) = \sum_{i=1}^{m} (f(x_i) - y_i)^2$$

即

$$E(w, b) = \sum_{i=1}^{m} (wx_i + b - y_i)^2$$

目标：

$$\min E(w, b)$$

称为：
最小二乘法（Least Squares）

3. 一元线性回归解析解

对 w, b 求偏导并令其为0:
得到:

$$w = \frac{\sum_{i=1}^{m}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{m}(x_i - \bar{x})^2}$$

$$b = \bar{y} - w\bar{x}$$

其中:

$$\bar{x} = \frac{1}{m}\sum x_i$$

$$\bar{y} = \frac{1}{m}\sum y_i$$

三、多元线性回归

1. 模型形式

$$f(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b$$

加入偏置项:

$$\hat{\mathbf{x}} = (x_1, x_2, \cdots, x_d, 1)^T$$

$$\hat{\mathbf{w}} = (w_1, w_2, \cdots, w_d, b)^T$$

则：

$$f(\mathbf{x}) = \hat{\mathbf{w}}^T \hat{\mathbf{x}}$$

---

2. 矩阵表示

样本矩阵：

$$X = \begin{bmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_m^T \end{bmatrix}$$

目标值：

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{bmatrix}$$

误差：

$$E = (Xw - y)^T (Xw - y)$$

---

3. 正规方程（Normal Equation）

令梯度为0：

$$\frac{\partial E}{\partial w} = 0$$

得到：

$$X^T X w = X^T y$$

若 $X^T X$ 可逆，则

$$w = (X^T X)^{-1} X^T y$$

考试高频。

四、对数几率回归（Logistic Regression）

虽然名字叫"回归"，实际上是：
分类模型

---

1. 单位阶跃函数的问题

理想分类：

$$y = \begin{cases} 1, & z > 0 \\ 0, & z \le 0 \end{cases}$$

即：

$$y = H(z)$$

其中 $H(z)$ 为阶跃函数。
问题：

- 不连续
- 不可导
- 不利于优化

---

2. Sigmoid 函数

用平滑函数近似：

$$y = \frac{1}{1 + e^{-z}}$$

其中：

$$z = \mathbf{w}^T \mathbf{x} + b$$

称为：
对数几率函数（Logistic Function）
图像特点：

- S 型曲线
- 输出范围 $(0, 1)$

---

3. 对数几率形式

由

$$p(y = 1|x) = \frac{1}{1 + e^{-(w^T x + b)}}$$

推导：

$$\ln \frac{p}{1 - p} = w^T x + b$$

左边称：
对数几率（log-odds）

---

4. 极大似然估计

似然函数：

$$L(w,b)=\prod_{i=1}^{m} p_i^{y_i}(1-p_i)^{1-y_i}$$

取对数：

$$\ell(w,b)=\sum_{i=1}^{m}\Big[y_i\ln p_i+(1-y_i)\ln(1-p_i)\Big]$$

目标：

$$\max \ell(w,b)$$

等价于：

$$\min\left(-\ell(w,b)\right)$$

即交叉熵损失。

---

5. Logistic 回归特点

优点：

- 输出概率
- 可解释性强
- 分类效果好

缺点：

- 本质仍是线性分类器
- 对复杂非线性问题能力有限

五、线性判别分析（LDA）

Linear Discriminant Analysis
主要用于：

- 二分类
- 降维

---

1. 基本思想

寻找投影方向 w，使得：

类内距离尽量小 within-class

类间距离尽量大 between-class

---

2. 投影后均值

正例均值：μ_1
负例均值：μ_0
投影后：

$$w^T\mu_1, \quad w^T\mu_0$$

希望二者距离大：

$$(w^T\mu_1 - w^T\mu_0)^2$$

---

3. 类内散度矩阵

$$S_w = S_0 + S_1$$

其中：

$$S_0 = \sum_{x \in D_0} (x - \mu_0)(x - \mu_0)^T$$

$$S_1 = \sum_{x \in D_1} (x - \mu_1)(x - \mu_1)^T$$

---

4. 类间散度矩阵

$$S_b = (\mu_1 - \mu_0)(\mu_1 - \mu_0)^T$$

刻画两类均值在特征空间中的分离程度。投影后类间距离可写为：

$$w^T S_b w = (w^T(\mu_1 - \mu_0))^2$$

---

5. Fisher 准则

定义：

$$J(w) = \frac{w^T S_b w}{w^T S_w w}$$

等价形式：

$$J(w) = \frac{(w^T(\mu_1 - \mu_0))^2}{w^T S_w w}$$

目标：

$$\max J(w)$$

---

6. 最优解

最终得到：

$$w = S_w^{-1}(\mu_1 - \mu_0)$$

考试重点公式。

六、多分类学习

Logistic 回归本身是二分类。
多分类常用：

---

1. OvO（One vs One）

若有 N 类，训练

$$\frac{N(N-1)}{2}$$

个分类器。
例如 5 类：

$$\frac{5 \times 4}{2} = 10$$

个分类器。
预测：
投票法。

---

2. OvR（One vs Rest）

训练 N 个分类器。
每次：

- 一类为正类
- 其余全部为反类

预测：
取最大置信度。

---

3. MvM（Many vs Many）

西瓜书中提到：
ECOC（纠错输出码）
思想：
将多分类转化为多个二分类问题。
特点：

- 容错能力强
- 抗噪声能力强

七、类别不平衡问题

问题

例如：

- 正样本100个
- 负样本10000个

若全部预测为负，准确率 99%，但毫无意义。

解决方法

1. 重采样

上采样（Over Sampling）

- 增加少数类

下采样（Under Sampling）

- 减少多数类

---

2. 阈值移动

原判定:

$$\frac{p}{1-p} > 1$$

即:

$$p > 0.5$$

修改阈值:

$$p > \tau$$

提高少数类识别能力。

八、本章模型关系总结（考试爱考）

模型	任务	输出
线性回归	回归	连续值
Logistic 回归	分类	概率
LDA	分类+降维	投影方向

Logistic 回归与 LDA 比较

项目	Logistic	LDA
思想	概率模型	投影模型
优化目标	极大似然	Fisher 准则
输出	概率	投影结果
决策边界	线性	线性

考试重点公式速记

1. 线性模型

$$f(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b$$

---

2. 最小二乘

$$E = (Xw - y)^T(Xw - y)$$

---

3. 正规方程

$$w = (X^T X)^{-1} X^T y$$

---

4. Logistic函数

$$p = \frac{1}{1 + e^{-z}}$$

---

5. 对数几率

$$\ln \frac{p}{1-p} = \mathbf{w}^T \mathbf{x} + b$$

---

6. Fisher准则

$$J(w) = \frac{w^T S_b w}{w^T S_w w}$$

---

7. 类间/类内散度矩阵

$$S_w = S_0 + S_1, \quad S_b = (\mu_1 - \mu_0)(\mu_1 - \mu_0)^T$$

---

8. LDA最优方向

$$w = S_w^{-1}(\mu_1 - \mu_0)$$

如果是按照**期末考试/考研复习**的要求，建议重点掌握：
★★★★★

- 最小二乘法推导
- 正规方程
- Logistic 回归原理与极大似然
- LDA 的 Fisher 准则及最优解

★★★★

- OvO、OvR、ECOC
- 类别不平衡处理

★★★

- 各模型优缺点比较与适用场景

第 4 章 决策树

这一章是机器学习课程中的**高频考点**，考试通常会涉及：

- 决策树生成过程
- 信息熵与纯度
- 信息增益
- 信息增益率
- 基尼指数
- ID3、C4.5、CART 的区别
- 剪枝
- 连续值处理
- 缺失值处理

一、决策树基本思想

决策树是一种树形分类模型。核心思想：不断选择最优属性对样本进行划分，使划分后的数据集尽可能“纯”。
例如：

```
是否有房?
├── 是 → 批准贷款
└── 否
    ├── 收入高 → 批准
    └── 收入低 → 拒绝
```

决策树生成流程

```
开始 → 选择最优划分属性 → 划分样本集 → 对子节点递归构建
→ 满足停止条件 → 生成叶节点
```

停止条件：

1. 当前样本全属于同一类别
2. 属性全部用完
3. 当前样本集为空

二、纯度（Purity）

纯度：一个节点中的样本属于同一类别的程度。

- 高纯度：`正 正 正 正 正`
- 低纯度：`正 正 负 正 负`

划分目标：父节点纯度低 → 划分 → 子节点纯度高，即**希望划分后节点越来越纯**。

三、信息熵（Entropy）

信息熵是衡量不确定性的指标。设 p_k 表示第 k 类样本占比，则：

$$\mathrm{Ent}(D) = -\sum_{k=1}^{K} p_k \log_2 p_k$$

性质：

- 完全纯（如 100% 正类）：$\mathrm{Ent}(D) = 0$
- 二分类均匀分布（50% 正、50% 负）：$\mathrm{Ent}(D) = 1$（二分类最大）

结论：**熵越大 → 越混乱；熵越小 → 越纯**。

四、信息增益（Information Gain）

ID3 的核心。
定义：划分前熵 $\mathrm{Ent}(D)$；划分后熵 $\sum_{v=1}^{V} \frac{|D^v|}{|D|}\mathrm{Ent}(D^v)$，则

$$\mathrm{Gain}(D, a) = \mathrm{Ent}(D) - \sum_{v=1}^{V} \frac{|D^v|}{|D|}\mathrm{Ent}(D^v)$$

含义：使用属性 a 划分后，熵减少了多少。
选择原则：$\max \mathrm{Gain}(D, a)$，信息增益最大的属性作为划分属性。
缺点：偏向取值数目多的属性。例如“学号”每人不同 → 一个叶子一个样本，熵直接变 0，信息增益极大，但毫无泛化能力。

五、信息增益率（Gain Ratio）

C4.5 核心，用于解决 ID3 偏好取值多属性的问题。
固有值（Intrinsic Value）：

$$\mathrm{IV}(a) = -\sum_{v=1}^{V} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

信息增益率：

$$\text{GainRatio}(D,a)=\frac{\text{Gain}(D,a)}{\text{IV}(a)}$$

作用：属性取值越多，$\text{IV}(a)$ 越大，从而抑制信息增益的虚高。
C4.5 实际做法（不是直接选最大增益率）：

1. 先筛选：信息增益高于平均值的属性
2. 再选：增益率最大的属性

六、基尼指数（Gini Index）

CART 核心。
基尼值：

$$\text{Gini}(D)=1-\sum_{k=1}^{K}p_k^2$$

二分类：设 p 为正类比例，则 $\text{Gini}(D)=2p(1-p)$。
性质：纯节点 $\text{Gini}=0$；50%-50% 时 $\text{Gini}=0.5$ 最大。结论：**基尼越小，纯度越高。**
属性划分后的基尼指数：

$$\text{GiniIndex}(D,a)=\sum_{v}\frac{|D^v|}{|D|}\text{Gini}(D^v)$$

选择原则：$\min \text{GiniIndex}$。

七、ID3、C4.5、CART比较（重点）

算法	划分标准
ID3	信息增益
C4.5	信息增益率
CART	基尼指数

ID3

提出：Quinlan。特点：

- 使用信息增益
- 只能处理离散属性
- 不支持剪枝（原始版本）

C4.5

改进 ID3。特点：

- 使用信息增益率
- 支持连续属性
- 支持缺失值
- 支持剪枝

CART

Classification And Regression Tree。特点：

- 使用基尼指数
- 二叉树
- 可做分类、可做回归

工业界应用广泛。

树结构区别

ID3/C4.5：多叉树（如颜色 → 红/蓝/黄/黑各一支）。
CART：二叉树（如 颜色=红? → 是/否）。

八、剪枝（Pruning）

决策树容易**过拟合**（训练集记住、训练准确率 100%、测试效果差）。**剪枝思想**：删除不必要的分支，提高泛化能力。

1. 预剪枝（Pre-pruning）

边生成边判断。流程：尝试划分 → 验证集性能提升？ → 是则划分，否则停止。
优点：训练快、树较小。缺点：容易欠拟合。

2. 后剪枝（Post-pruning）

先长成完整树，再向上剪枝。流程：生成完整树 → 考察某子树 → 剪掉后性能提升？ → 是则剪，否则保留。
优点：泛化能力更强。缺点：计算量大。

方法	特点
预剪枝	易欠拟合
后剪枝	效果通常更好

九、连续值处理

ID3 只能处理离散值；现实中年龄、身高、收入等多为连续值。C4.5 思想：**离散化**。

1. **排序**：如 $10, 20, 30, 40, 50$
2. **构造候选划分点**（相邻值平均）：

$$T = \{15, 25, 35, 45\}$$

3. **分别计算** 年龄$\leqslant$15?、$\leqslant$25?、$\leqslant$35?、$\leqslant$45? 等信息增益率
4. **选择最优划分点**，形成如 `年龄≤35? 是 / 否`

十、缺失值处理

不完整样本若直接剔除，会造成大量信息浪费。西瓜书用**样本权重**统一处理缺失值（原始 ID3 不处理缺失值）。
需解决两个问题：

1. 属性值缺失时，**如何选择划分属性**？
2. 划分属性已确定，样本在该属性上缺失，**如何划分到子结点**？

学习开始时，各样本权值 $w_{\boldsymbol{x}} = 1$；往下传递时按下列规则更新。

问题 1：如何选择划分属性？

对候选属性 a，记 $\tilde{D}$ 为 D 中在属性 a 上**无缺失值**的样本子集。
无缺失样本权重占比：

$$\rho = \frac{\sum_{\boldsymbol{x} \in \tilde{D}} w_{\boldsymbol{x}}}{\sum_{\boldsymbol{x} \in D} w_{\boldsymbol{x}}}$$

在 $\tilde{D}$ 上定义（均按权重计数）：

$$\tilde{p}_k = \frac{\sum_{\boldsymbol{x} \in \tilde{D}_k} w_{\boldsymbol{x}}}{\sum_{\boldsymbol{x} \in \tilde{D}} w_{\boldsymbol{x}}} \quad (1 \leqslant k \leqslant |\mathcal{Y}|)$$

$$\tilde{r}_v = \frac{\sum_{\boldsymbol{x} \in \tilde{D}^v} w_{\boldsymbol{x}}}{\sum_{\boldsymbol{x} \in \tilde{D}} w_{\boldsymbol{x}}} \quad (1 \leqslant v \leqslant V)$$

其中 $\tilde{D}_k$ 为 $\tilde{D}$ 中属于第 k 类的样本，$\tilde{D}^v$ 为 $\tilde{D}$ 中在 a 上取值为 a^v 的样本。显然 $\sum_k \tilde{p}_k = 1$，$\sum_v \tilde{r}_v = 1$。
信息增益推广为（式 4.9）：

$$\mathrm{Gain}(D, a) = \rho \times \left(\mathrm{Ent}(\tilde{D}) - \sum_{v=1}^{V} \tilde{r}_v \, \mathrm{Ent}(\tilde{D}^v) \right)$$

其中 $\mathrm{Ent}(\tilde{D}) = -\sum_{k=1}^{|\mathcal{Y}|} \tilde{p}_k \log_2 \tilde{p}_k$。
含义：仅在无缺失子集 $\tilde{D}$ 上计算增益，再乘 ρ **折价**——属性 a 缺失越多，ρ 越小，该属性越不易被选中。
若用 C4.5 的**信息增益率**，$\mathrm{IV}(a)$ 同样在 $\tilde{D}$ 上用 $\tilde{r}_v$ 计算，再与上述 $\mathrm{Gain}(D, a)$ 组合。

问题 2：样本在该属性上缺失，如何划分？

设划分属性为 a，样本 $\boldsymbol{x}$ 在 a 上的取值：

情况	划分方式
已知 a^v	划入对应子结点，权值保持 $w_{\boldsymbol{x}}$
缺失	同时划入 a 的全部 V 个子结点；进入子结点 v 后权值为 $w_{\boldsymbol{x}} \times \tilde{r}_v$

例（西瓜书表 4.4）：以属性「色泽」划分，无缺失子集中青绿、乌黑、浅白的权重比为 $\frac{7}{15}, \frac{5}{15}, \frac{3}{15}$，则色泽缺失的样本分别以这三个比例进入三个子结点。
预测：测试样本划分规则与训练相同；叶结点类别由加权类别比例决定（权重大者为预测类）。

十一、考试常考公式汇总

信息熵

$$\mathrm{Ent}(D) = -\sum_{k} p_k \log_2 p_k$$

信息增益

$$\mathrm{Gain}(D, a) = \mathrm{Ent}(D) - \sum_{v} \frac{|D^v|}{|D|} \mathrm{Ent}(D^v)$$

固有值

$$\mathrm{IV}(a) = -\sum_{v} \frac{|D^v|}{|D|} \log_2 \frac{|D^v|}{|D|}$$

信息增益率

$$\mathrm{GainRatio}(D,a)=\frac{\mathrm{Gain}(D,a)}{\mathrm{IV}(a)}$$

基尼值

$$\mathrm{Gini}(D)=1-\sum_{k}p_k^2$$

基尼指数

$$\mathrm{GiniIndex}(D,a)=\sum_{v}\frac{|D^v|}{|D|}\mathrm{Gini}(D^v)$$

缺失值下的信息增益（式 4.9）

$$\mathrm{Gain}(D,a)=\rho\times\left(\mathrm{Ent}(\tilde{D})-\sum_{v=1}^{V}\tilde{r}_v\,\mathrm{Ent}(\tilde{D}^v)\right)$$

缺失样本划分：进入子结点 v 的权值 $w_{\boldsymbol{x}}\leftarrow w_{\boldsymbol{x}}\times\tilde{r}_v$。

十二、一张表记住全部

内容	核心思想
纯度	节点越单一越好
信息熵	衡量混乱程度
信息增益	熵减少量
信息增益率	信息增益修正版
基尼指数	不纯度指标
预剪枝	提前停止生长
后剪枝	先长树再修剪
连续值处理	选择最佳划分点
缺失值处理	ρ 折价 + $\tilde{r}_v$ 多分支配权
ID3	信息增益
C4.5	信息增益率
CART	基尼指数+二叉树

期末考试重点等级

★★★★★（必考）

- 信息熵计算
- 信息增益计算
- 信息增益率计算
- 基尼指数计算
- ID3、C4.5、CART比较

★★★★

- 预剪枝与后剪枝
- 连续值处理

★★★

- 缺失值处理中的权重分配思想

最容易出计算题：

1. 根据信息熵求信息增益并选择划分属性（ID3）
2. 根据信息增益率选择属性（C4.5）
3. 根据基尼指数选择属性（CART）
4. 比较预剪枝与后剪枝的优缺点

第5章 神经网络

这一章考试通常不会要求推导特别复杂的矩阵公式，但会重点考察：

- 神经元模型
- 感知机（Perceptron）
- 多层前馈神经网络
- BP（BackPropagation，误差逆传播）算法
- 标准BP与累积BP
- 神经网络训练中的常见问题

其中**感知机和 BP 算法是绝对重点**。

一、神经元模型（M-P 神经元）

生物神经元启发

神经网络来源于对生物神经元的模拟：`树突 → 接收信号；胞体 → 处理信号；轴突 → 输出信号`。
对应数学模型：

$$y = f\left(\sum_i w_i x_i - \theta\right)$$

其中：x_i 输入，w_i 权重，θ 阈值，$f(\cdot)$ 激活函数。

简化形式

令 $b = -\theta$，则

$$y = f(\mathbf{w}^T\mathbf{x} + b)$$

这是后面所有神经网络的基础形式。

二、激活函数

为什么需要激活函数?

若无激活函数，$y = \mathbf{w}^T\mathbf{x} + b$，多层网络仍等价于一层线性模型，无法表示复杂关系。

Sigmoid 函数

西瓜书重点:

$$f(x) = \frac{1}{1 + e^{-x}}, \quad 0 < f(x) < 1$$

导数（考试常考）

$$f'(x) = f(x)(1 - f(x))$$

Tanh 函数

$$f(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

输出范围 $(-1, 1)$。

三、感知机（Perceptron）

最早的神经网络模型。

1. 感知机模型

$$y = \text{sign}(\mathbf{w}^T\mathbf{x} + b)$$

其中

$$\text{sign}(z) = \begin{cases} 1, & z \geq 0 \\ -1, & z < 0 \end{cases}$$

2. 几何意义

决策边界 $\mathbf{w}^T\mathbf{x} + b = 0$：二维为直线，三维为平面，高维为超平面。例：$2x_1 + x_2 - 3 = 0$ 将空间分成两部分。

3. 感知机学习规则

对误分类样本 $(\mathbf{x}_i, y_i)$，$y_i \in \{+1, -1\}$，更新：

$$\mathbf{w} \leftarrow \mathbf{w} + \eta y_i \mathbf{x}_i, \quad b \leftarrow b + \eta y_i$$

η 为学习率。

理解

- 正样本被错分（$y_i = +1$）：$\mathbf{w} \leftarrow \mathbf{w} + \eta\mathbf{x}_i$，决策面向该样本移动
- 负样本被错分（$y_i = -1$）：$\mathbf{w} \leftarrow \mathbf{w} - \eta\mathbf{x}_i$，决策面反方向移动

4. 感知机收敛定理

若训练集线性可分，则感知机有限步内收敛。

5. 感知机缺陷

XOR 问题

```
(0,0)→0  (0,1)→1  (1,0)→1  (1,1)→0
```

无法用一条直线分开。**单层感知机只能解决线性可分问题**。

四、多层前馈神经网络

结构

```
输入层 → 隐藏层 → 输出层
```

例：输入层(4) → 隐藏层(5) → 输出层(2)。

通用逼近能力

只要隐藏层足够多（或神经元足够多），神经网络可以逼近任意连续函数。

为什么能解决 XOR?

隐藏层进行非线性变换，原本线性不可分的数据变得线性可分。

五、BP 算法（BackPropagation）

考试核心。训练目标：调整权重使误差最小。

1. BP 算法思想

```
前向传播 → 计算误差 → 反向传播 → 更新权重 → 重复
```

2. 前向传播

输入层 x_i，隐藏层输出 b_h，输出层输出 $\hat{y}_j$。
隐藏层：

$$\alpha_h = \sum_i v_{ih} x_i, \quad b_h = f(\alpha_h - \gamma_h)$$

输出层：

$$\beta_j = \sum_h w_{hj} b_h, \quad \hat{y}_j = f(\beta_j - \theta_j)$$

3. 误差函数

单样本平方误差：

$$E_k = \frac{1}{2} \sum_j (\hat{y}_j - y_j)^2$$

4. BP 核心思想

利用链式法则求 $\frac{\partial E}{\partial w}$，即误差对每个权重的影响。

六、输出层误差项

定义输出层梯度 g_j，推导结果（考试常考，需记忆）：

$$g_j = \hat{y}_j (1 - \hat{y}_j)(y_j - \hat{y}_j)$$

含义：输出层神经元的误差信号。

七、隐藏层误差项

定义隐藏层梯度 e_h：

$$e_h = b_h(1-b_h)\sum_j w_{hj}g_j$$

理解：输出层误差 → 逐层向后传递 → 隐藏层误差，即**误差逆传播**。

八、权值更新公式（重点）

输出层权值 w_{hj}

$$\Delta w_{hj} = \eta g_j b_h, \quad w_{hj} \leftarrow w_{hj} + \eta g_j b_h$$

输入层权值 v_{ih}

$$\Delta v_{ih} = \eta e_h x_i, \quad v_{ih} \leftarrow v_{ih} + \eta e_h x_i$$

记忆口诀

> 输出层：梯度 × 隐层输出
> 隐藏层：梯度 × 输入

九、标准 BP 与累积 BP

西瓜书特色考点。

标准BP（Standard BP）

每处理一个样本立即更新权值（样本1更新 → 样本2更新 → …）。
优点：更新快。缺点：波动大。

累积BP（Batch BP）

先计算全部样本梯度再统一更新（各样本梯度求和 → 更新一次）。
优点：稳定。缺点：慢。

方法	更新频率
标准BP	每个样本一次
累积BP	每轮一次

十、局部极小问题

神经网络优化属非凸优化，可能出现局部最优 $\neq$ 全局最优。常见应对：多次随机初始化、动量法、随机梯度下降。

十一、过拟合问题

神经网络参数多，容易过拟合。解决方法：

1. 早停法

验证误差开始上升时停止训练。

2. 正则化

目标函数 $E + \lambda \|\mathbf{w}\|^2$。

3. 增加训练数据

最有效。

十二、感知机与BP网络比较

项目	感知机	BP网络
层数	单层	多层
激活函数	Sign	Sigmoid等
分类能力	线性可分	非线性
XOR	不能解决	能解决
学习算法	感知机规则	BP算法

十三、考试必背公式

感知机

$$f(\mathbf{x}) = \text{sign}(\mathbf{w}^T\mathbf{x} + b), \quad \mathbf{w} \leftarrow \mathbf{w} + \eta y \mathbf{x}, \quad b \leftarrow b + \eta y$$

Sigmoid

$$f(x) = \frac{1}{1+e^{-x}}, \quad f'(x) = f(x)(1-f(x))$$

输出层误差项

$$g_j = \hat{y}_j(1-\hat{y}_j)(y_j - \hat{y}_j)$$

隐藏层误差项

$$e_h = b_h(1-b_h)\sum_j w_{hj} g_j$$

权值更新

$$\Delta w_{hj} = \eta g_j b_h, \quad \Delta v_{ih} = \eta e_h x_i$$

十四、一张图串起全章

```
神经网络
│
├── 神经元模型
│   └── y=f(wTx+b)
│
├── 感知机
│   ├── sign函数
│   ├── 线性分类
│   ├── 感知机学习规则
│   └── XOR无法解决
│
├── 多层前馈网络
│   ├── 输入层
│   ├── 隐藏层
│   └── 输出层
│
└── BP算法
    ├── 前向传播
    ├── 误差计算
    ├── 反向传播
    ├── 权值更新
    ├── 标准BP
    └── 累积BP
```

期末考试重点等级

★★★★★（必考）

- 感知机模型与更新规则
- XOR 问题
- BP 算法流程
- 输出层/隐藏层误差项
- 权值更新公式
- 标准BP 与累积BP 区别

★★★★

- Sigmoid 函数及导数
- 局部极小问题
- 过拟合与解决方法

★★★

- 神经元模型
- 通用逼近性质

最容易出计算题：

1. 给定感知机训练样本，计算一次或几次权值更新
2. 给定简单三层网络，计算一次前向传播结果
3. 根据给定输出误差，计算 BP 误差项和权值更新量

第6章 支持向量机（SVM）

这一章是《西瓜书》中**数学味最浓、考试最容易出推导题**的一章。抓重点可沿两条主线理解：

> 超平面（如何分类）→ 支持向量（谁决定超平面）

一、什么是支持向量机?

支持向量机（Support Vector Machine，SVM）是一种**二分类、线性分类器、最大间隔**分类模型。
目标：在所有能正确划分训练集的超平面中，找到**间隔最大**的那个。

二、超平面（Hyperplane）

1. 超平面定义

分类面：

$$\mathbf{w}^T\mathbf{x} + b = 0$$

称为超平面，其中 $\mathbf{w} = (w_1, w_2, \cdots, w_d)^T$。

2. 几何意义

- 二维：$w_1x_1 + w_2x_2 + b = 0$ 为直线
- 三维：为平面
- 高维：统称超平面

3. 分类规则

设 $f(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b$，则：

- $f(\mathbf{x}) > 0 \rightarrow$ 预测正类
- $f(\mathbf{x}) < 0 \rightarrow$ 预测负类
- $f(\mathbf{x}) = 0 \rightarrow$ 位于分类面上

考试常问：超平面由什么决定？答：$\mathbf{w}$, b。

三、样本点到超平面的距离

样本 $\mathbf{x}_i$ 到超平面 $\mathbf{w}^T\mathbf{x} + b = 0$ 的距离：

$$d_i = \frac{|\mathbf{w}^T\mathbf{x}_i + b|}{\|\mathbf{w}\|}$$

这是推导间隔的基础，**必须记住**。

四、函数间隔与几何间隔

对样本 $(\mathbf{x}_i, y_i)$，$y_i \in \{+1, -1\}$：

1. 函数间隔

$$\hat{\gamma}_i = y_i(\mathbf{w}^T\mathbf{x}_i + b)$$

特点：受 $\mathbf{w}, b$ 缩放影响。

2. 几何间隔

$$\gamma_i = \frac{y_i(\mathbf{w}^T\mathbf{x}_i + b)}{\|\mathbf{w}\|}$$

特点：真正反映距离，**不受缩放影响**。
关系（考试高频）：

$$\hat{\gamma} = y(\mathbf{w}^T\mathbf{x} + b), \quad \gamma = \frac{\hat{\gamma}}{\|\mathbf{w}\|}$$

五、支持向量（Support Vector）

定义：距离分类超平面最近的训练样本。

```
○ ○ ○     ← 正类
○ ○
---------  ← 间隔边界 / 分类面 / 间隔边界
× ×       ← 负类
× × ×
```

最靠近分类面的点即支持向量。
为何重要：最优超平面**完全由支持向量决定**；删远离边界的样本，超平面几乎不变；删支持向量，超平面会变。
考试标准表述：距离分类超平面最近的训练样本称为支持向量

六、间隔（Margin）

1. 支持向量所在边界

规定支持向量满足 $y_i(\mathbf{w}^T\mathbf{x}_i + b) = 1$，则两条边界为：

$$\mathbf{w}^T\mathbf{x} + b = 1, \quad \mathbf{w}^T\mathbf{x} + b = -1$$

分类超平面 $\mathbf{w}^T\mathbf{x} + b = 0$ 位于中间：

```
+1 边界
---------
分类面
---------
-1 边界
```

2. 间隔宽度

两条边界之间距离（**考试必背**）：

$$\text{Margin} = \frac{2}{\|\mathbf{w}\|}$$

3. 最大间隔思想

SVM 目标：

$$\max \frac{2}{\|\mathbf{w}\|} \quad \Leftrightarrow \quad \min \frac{1}{2}\|\mathbf{w}\|^2$$

这是 SVM 优化目标的来源。

七、线性可分支持向量机（硬间隔）

训练集 $D=\{(\mathbf{x}_i, y_i)\}$，要求 $y_i(\mathbf{w}^T\mathbf{x}_i+b)\geq 1$。
优化问题：

$$\min_{\mathbf{w},b} \frac{1}{2}\|\mathbf{w}\|^2$$

$$\text{s.t.} \quad y_i(\mathbf{w}^T\mathbf{x}_i+b)\geq 1, \quad i=1,\dots,m$$

考试高频：为何最小化 $\|\mathbf{w}\|^2$？因为 $\text{Margin}=\frac{2}{\|\mathbf{w}\|}$，**最大间隔 ⇔ 最小范数**。

求解思路：拉格朗日对偶

原问题（**主问题 / 原始形式**）是带约束的凸二次规划，直接求 $\mathbf{w},b$ 不便；西瓜书通过**拉格朗日乘子法转为对偶问题**求解，并为核技巧铺路。
引入拉格朗日乘子 $\alpha_i\geq 0$，构造拉格朗日函数：

$$L(\mathbf{w},b,\boldsymbol{\alpha})=\frac{1}{2}\|\mathbf{w}\|^2+\sum_{i=1}^{m}\alpha_i\big(1-y_i(\mathbf{w}^T\mathbf{x}_i+b)\big)$$

对 $\mathbf{w},b$ 求偏导并令为零：

$$\frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^{m} \alpha_i y_i \mathbf{x}_i = 0 \quad \Rightarrow \quad \mathbf{w} = \sum_{i=1}^{m} \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = \sum_{i=1}^{m} \alpha_i y_i = 0$$

代入 L 消去 $\mathbf{w}, b$，得到**对偶问题**（只含 $\boldsymbol{\alpha}$）：

$$\max_{\boldsymbol{\alpha}} \quad \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i=1}^{m} \sum_{j=1}^{m} \alpha_i \alpha_j y_i y_j \, \mathbf{x}_i^T \mathbf{x}_j$$

$$\text{s.t.} \quad \sum_{i=1}^{m} \alpha_i y_i = 0, \quad \alpha_i \geq 0, \quad i = 1, \ldots, m$$

优点：①变量个数为 m（样本数），高维时若 $m \ll d$ 更易解；②目标仅含内积 $\mathbf{x}_i^T \mathbf{x}_j$，便于推广到核函数。

KKT 条件与支持向量

硬间隔、线性可分下，最优解满足 **KKT 条件**（考试常考结论）：

样本类型	条件	含义
支持向量	$\alpha_i > 0$ 且 $y_i(\mathbf{w}^T\mathbf{x}_i + b) = 1$	落在间隔边界上，**决定超平面**
非支持向量	$\alpha_i = 0$	在间隔边界之外，对 $\mathbf{w}$ 无贡献

因此 $\mathbf{w}$ 可写为支持向量的线性组合：

$$\mathbf{w} = \sum_{i \in SV} \alpha_i y_i \mathbf{x}_i$$

其中 SV 为支持向量下标集合。
偏移 b 的求法：任取一支持向量 $(\mathbf{x}_s, y_s)$，由 $y_s(\mathbf{w}^T\mathbf{x}_s + b) = 1$ 得

$$b = y_s - \mathbf{w}^T \mathbf{x}_s$$

（实践中可对多个支持向量取平均以提高数值稳定性。）

预测函数（对偶形式）

$$f(\mathbf{x}) = \text{sign}\left(\sum_{i \in SV} \alpha_i y_i \, \mathbf{x}_i^T \mathbf{x} + b \right)$$

求解流程小结：

```
原始问题（主问题）
    ↓ 拉格朗日对偶
对偶问题（只含 alpha）
    ↓ 解得 alpha
alpha>0 → 支持向量 → 计算 w、b → 预测
```

对应公式：

1. 原始问题：$\min_{\mathbf{w},b} \frac{1}{2}\|\mathbf{w}\|^2$，s.t. $y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1$
2. 对偶问题：$\max_{\boldsymbol{\alpha}} \sum_i \alpha_i - \frac{1}{2}\sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j$，s.t. $\sum_i \alpha_i y_i = 0$，$\alpha_i \geq 0$
3. $\alpha_i > 0 \rightarrow$ 支持向量 $\rightarrow \mathbf{w} = \sum_{i \in SV} \alpha_i y_i \mathbf{x}_i$，求 $b \rightarrow f(\mathbf{x}) = \text{sign}(\cdots)$

八、软间隔支持向量机

现实数据常线性不可分。引入松弛变量 $\xi_i \geq 0$：

$$y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1 - \xi_i$$

优化目标：

$$\min \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_i \xi_i$$

参数 C 的作用

在分类错误与间隔大小之间权衡：

C	含义	效果
大	严格分类，间隔可变小	易过拟合
小	允许部分错误，间隔更大	泛化更强

软间隔与 Hinge 损失

记 $z_i = y_i(\mathbf{w}^T\mathbf{x}_i + b)$ 为样本间隔方向的输出，则松弛变量可写为

$$\xi_i = \max(0,\, 1 - z_i)$$

即 **Hinge** 损失 $\ell_{\text{hinge}}(z) = \max(0, 1-z)$。软间隔 SVM 等价于

$$\min_{\mathbf{w},b}\ \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m}\max\bigl(0,\, 1 - y_i(\mathbf{w}^T\mathbf{x}_i + b)\bigr)$$

在间隔内（$0 < z_i < 1$）仍计损失，$z_i \geq 1$ 后损失为 0 且不再增大（**上界有界**），对异常点相对稳健。

三种常见替代损失函数（西瓜书图 6.5）

分类任务希望最小化**0-1** 损失（分错为 1，分对为 0），但 0-1 损失不可导、难优化。常用替代损失作为其上界或凸近似，记 $z = y \cdot f(\mathbf{x})$（$f$ 为实值输出，如 $\mathbf{w}^T\mathbf{x} + b$）：

损失	公式 $\ell(z)$	典型算法	特点
Hinge（合页）	$\max(0, 1-z)$	SVM / 软间隔 SVM	间隔 ≥ 1 后损失为 0；对 z 增大**不再惩罚**；鼓励大间隔
Logistic（对率）	$\log(1+e^{-z})$	Logistic 回归	处处光滑；$z \to -\infty$ 时仍缓慢增加；输出可解释为概率
Exponential（指数）	e^{-z}	AdaBoost 等	误分类惩罚**指数增长**；对难例、噪声更敏感

与 **0-1 损失** 的关系（直观）：当 $z<0$（分错）时三者均显著大于 0；当 z 很大（分对且置信度高）时，Hinge 已为 0，Logistic / Exponential 仍 >0 但很小。
对比记忆：

- **SVM + Hinge**：要**大间隔**，只关心间隔边界附近，误分线性惩罚、分对足够好即停。
- **Logistic**：要**概率拟合**，全体样本持续施加光滑惩罚。
- **Exponential**：要**压低难例权重**，误分代价增长最快，提升集成方法对错例的关注度。

统一写法（理解即可）：

$$\min_{f} \sum_{i=1}^{m} \ell\big(y_i f(\mathbf{x}_i)\big) + \lambda\, \Omega(f)$$

其中 ℓ 取 Hinge 即得软间隔 SVM 形式；取 Logistic 即接近对数似然；正则项 $\Omega(f)=\|\mathbf{w}\|^2$ 控制模型复杂度。

九、核函数思想

为何需要核函数？ 许多数据在原空间线性不可分（如圆形分布），映射到高维 $\phi(\mathbf{x})$ 后可能线性可分。
思想：$\mathbf{x} \to \phi(\mathbf{x})$，再在高维空间找超平面。

十、核函数与核技巧

定义：

$$K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j)$$

核技巧（Kernel Trick）：无需显式计算 $\phi(\mathbf{x})$，即可在高维特征空间完成运算。

十一、常见核函数

核函数	形式	说明
线性核	$K(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{z}$	等价于原空间线性 SVM
多项式核	$K(\mathbf{x}, \mathbf{z}) = (\mathbf{x}^T \mathbf{z} + c)^d$	含阶数 d
高斯核（RBF）	$K(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|^2}{2\sigma^2}\right)$	**应用最广，考试最爱问**

十二、支持向量机回归（SVR）

分类变回归：允许误差在 ε 范围内不计损失，称 **ε-不敏感损失**。

```
真实值
========  ±ε 带内损失为 0
========
预测值
```

了解即可，考试频率低于分类 SVM。

十三、感知机、Logistic 回归与 SVM 比较

三者决策边界在特征空间中都可是**线性的**（核 SVM 则在原空间非线性），但优化目标、输出形式与泛化机制不同。

项目	感知机	Logistic回归	SVM
模型类型	二分类	二分类（可推广多分类）	二分类（可推广多分类）
决策函数	$\text{sign}(\mathbf{w}^T\mathbf{x}+b)$	Sigmoid，输出 $P(y=1\|\mathbf{x})$	$\text{sign}(\mathbf{w}^T\mathbf{x}+b)$（间隔最大化）
决策边界	线性超平面	线性超平面（$p=0.5$ 等价于 $\mathbf{w}^T\mathbf{x}+b=0$）	线性超平面（最大间隔）
优化目标	误分类驱动，使样本分对即可	极大似然 / 最小化交叉熵	最大间隔，$\min \frac{1}{2}\|\mathbf{w}\|^2$（软间隔加 $C\sum\xi_i$）
损失思想	只关心是否分错	所有样本的概率拟合，错分置信度越大惩罚越大	关注**间隔边界附近**样本，间隔内/外误分类用松弛变量控制
关键样本	误分类样本参与更新	**全部样本**均参与（梯度由全体贡献）	仅**支持向量**决定超平面
输出	类别 ±1	**概率**（可解释、可调阈值）	类别（间隔距离可间接作置信度）
线性不可分	不能（如XOR）	不能（需特征变换等）	可用**核函数**映射到高维
收敛性	线性可分则有限步收敛	凸优化，通常收敛到全局最优	凸优化（对偶问题）
泛化能力	一般	较好（概率模型、稳定）	通常较强（结构风险/大间隔）
与第3章关系	神经网络、SVM 前身	同章线性分类概率模型	同章间隔最大化线性分类器

记忆要点：

- **感知机**：能分开就行，不追求间隔；无概率、无核。
- **Logistic**：要拟合**概率分布**，全体样本都起作用；边界仍是线性的，但优化的是对数似然。
- **SVM**：要**间隔最大**，由少数支持向量定边界；可用核处理非线性。

十四、本章核心公式

超平面与分类

$$\mathbf{w}^T\mathbf{x} + b = 0, \quad \text{sign}(\mathbf{w}^T\mathbf{x} + b)$$

点到超平面距离

$$d = \frac{|\mathbf{w}^T\mathbf{x} + b|}{\|\mathbf{w}\|}$$

函数间隔 / 几何间隔

$$\hat{\gamma} = y(\mathbf{w}^T\mathbf{x} + b), \quad \gamma = \frac{y(\mathbf{w}^T\mathbf{x} + b)}{\|\mathbf{w}\|}$$

间隔宽度

$$\text{Margin} = \frac{2}{\|\mathbf{w}\|}$$

硬间隔优化

$$\min \frac{1}{2}\|\mathbf{w}\|^2 \quad \text{s.t.} \quad y_i(\mathbf{w}^T\mathbf{x}_i + b) \geq 1$$

软间隔优化

$$\min \frac{1}{2}\|\mathbf{w}\|^2 + C\sum_i \xi_i$$

高斯核

$$K(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|^2}{2\sigma^2}\right)$$

十五、考试最常考的结论

1. **支持向量满足** $y_i(\mathbf{w}^T\mathbf{x}_i+b)=1$ 或 $=-1$（在间隔边界上）。
2. **最优超平面由支持向量决定。**
3. SVM 追求 $\boxed{\text{最大间隔}}$，而非仅分类正确。
4. $\dfrac{2}{\|\mathbf{w}\|}$ 最大 $\Leftrightarrow$ $\|\mathbf{w}\|^2$ 最小。
5. 核函数：$\boxed{\text{低维不可分，高维可分}}$，核技巧避免显式进入高维。

期末考试重点等级

★★★★★（必考）

- 超平面定义与分类规则
- 支持向量定义
- 点到超平面的距离
- 函数间隔与几何间隔
- 最大间隔思想
- 硬间隔与软间隔 SVM

★★★★

- 核函数思想
- 高斯核
- 参数 C 的作用

★★★

- SVR
- 常见核函数比较

最容易出推导/简答题：

1. 证明间隔宽度为 $\dfrac{2}{\|\mathbf{w}\|}$
2. 说明为何 SVM 目标函数是 $\min \dfrac{1}{2}\|\mathbf{w}\|^2$
3. 解释支持向量为何决定最优超平面

第7章 贝叶斯分类器

重点：贝叶斯决策论、朴素贝叶斯（Naive Bayes）。公式多、概念易混，主线：

> 先验概率 → 结合样本特征 → 后验概率 → 选概率最大的类

即：**贝叶斯决策 = 最大后验概率决策**。

一、贝叶斯决策论

1. 分类问题本质

给定样本 $\mathbf{x} = (x_1, x_2, \cdots, x_d)$，判断属于类别 $c_1, c_2, \cdots, c_K$（如天气→晴/雨，邮件→垃圾/正常）。

2. 后验概率

观察到 $\mathbf{x}$ 后，$P(c|\mathbf{x})$ 表示样本属于类别 c 的概率，称为**后验概率（Posterior）**。

3. 贝叶斯公式（考试必背）

$$P(c|\mathbf{x}) = \frac{P(\mathbf{x}|c)\,P(c)}{P(\mathbf{x})}$$

符号	名称	含义
$P(c)$	先验（Prior）	未观察样本前类别 c 出现的概率
$P(\mathbf{x}|c)$	类条件概率 / 似然（Likelihood）	在类别 c 下观察到 $\mathbf{x}$ 的概率
$P(c|\mathbf{x})$	后验（Posterior）	观察到 $\mathbf{x}$ 后属于 c 的概率
$P(\mathbf{x})$	证据（Evidence）	对所有类别相同，分类时常可省略

二、贝叶斯决策规则

因 $P(\mathbf{x})$ 与 c 无关，有

$$\arg\max_c P(c|\mathbf{x}) = \arg\max_c P(\mathbf{x}|c)\,P(c)$$

贝叶斯最优分类器：

$$h(\mathbf{x}) = \arg\max_c P(c|\mathbf{x})$$

即选择后验概率最大的类别。

三、朴素贝叶斯（Naive Bayes）

本章绝对重点。

为什么需要朴素贝叶斯?

直接估计 $P(\mathbf{x}|c) = P(x_1, \ldots, x_d|c)$ 需考虑所有属性组合，数据量**指数爆炸**（如年龄、收入、学历、职业同时组合）。故引入**条件独立假设**简化。

四、条件独立假设

朴素贝叶斯假设：给定类别 c，各属性**相互独立**：

$$P(x_1, x_2, \cdots, x_d|c) = \prod_{i=1}^{d} P(x_i|c)$$

这就是 **Naive（朴素）** 的含义——现实中往往不完全成立（如学历与收入相关），但实践中仍常有效。

五、朴素贝叶斯分类公式

由 $P(c|\mathbf{x}) \propto P(c)P(\mathbf{x}|c)$ 及独立假设：

$$P(c|\mathbf{x}) \propto P(c)\prod_{i=1}^{d} P(x_i|c)$$

分类规则（考试必背）：

$$h(\mathbf{x}) = \arg\max_{c} P(c)\prod_{i=1}^{d} P(x_i|c)$$

数值计算时常对概率取对数，避免下溢：$\arg\max_c \left[\log P(c) + \sum_i \log P(x_i|c)\right]$。

六、朴素贝叶斯计算例题

二维特征 $\mathbf{x} = (x_1, x_2)$：x_1=天气，x_2=湿度；类别 $c \in \{\text{是}, \text{否}\}$（是否打球）。

x_1（天气）	x_2（湿度）	打球 c
晴	高	是
晴	高	是
晴	正常	否
雨	高	否
雨	正常	否

共 $m = 5$ 条。由频率估计：
先验

$$P(\text{是}) = \frac{2}{5}, \quad P(\text{否}) = \frac{3}{5}$$

类条件（在各类别子集内统计）

概率	是（2 条）	否（3 条）
$P(x_1 = \text{晴} \,\|\, c)$	$\frac{2}{2} = 1$	$\frac{1}{3}$
$P(x_2 = \text{高} \,\|\, c)$	$\frac{2}{2} = 1$	$\frac{2}{3}$

由独立假设：$P(\mathbf{x}|c) = P(x_1|c)\,P(x_2|c)$。
新样本 $\mathbf{x}^* = (\text{晴}, \text{高})$：

$$P(\text{是}|\mathbf{x}^*) \propto P(\text{是})\,P(\text{晴}|\text{是})\,P(\text{高}|\text{是}) = \frac{2}{5} \times 1 \times 1 = \frac{2}{5} = 0.4$$

$$P(\text{否}|\mathbf{x}^*) \propto P(\text{否})\,P(\text{晴}|\text{否})\,P(\text{高}|\text{否}) = \frac{3}{5} \times \frac{1}{3} \times \frac{2}{3} = \frac{2}{15} \approx 0.133$$

$0.4 > 0.133$，故 $h(\mathbf{x}^*) = \arg\max_c P(c|\mathbf{x}^*) = $ 是（预测打球）。
对数形式（等价）：$\log P(\text{是}|\mathbf{x}^*) \propto \log\frac{2}{5}$，$\log P(\text{否}|\mathbf{x}^*) \propto \log\frac{3}{5} + \log\frac{1}{3} + \log\frac{2}{3}$，比较后仍判「是」。

七、拉普拉斯修正

考试高频。

问题

若某 $P(x_i|c) = 0$，则 $\prod_i P(x_i|c) = 0$，该类别直接被否决。例：训练集垃圾邮件中从未出现「优惠券」，则 $P(\text{优惠券}|\text{垃圾}) = 0$，新邮件含该词时 $P(\text{垃圾}|\mathbf{x}) = 0$，不合理。

公式

对离散属性 x_i：

$$P(x_i|c) = \frac{N_{ic}+1}{N_c+V}$$

- N_{ic}：类别 c 中属性 i 取该值的次数
- N_c：类别 c 的样本数
- V：属性 i 可能取值数

作用：**避免零概率**（拉普拉斯平滑）。

计算例题（接 六 数据集）

§六 中「是」类 2 条均为 (晴, 高)，故 $P(\text{雨}|\text{是})=0$、$P(\text{正常}|\text{是})=0$。**新样本** $\mathbf{x}^*=(\text{晴},\text{正常})$ 时，未修正：

$$P(\text{是}|\mathbf{x}^*) \propto \frac{2}{5} \times \underbrace{1}_{P(\text{晴}|\text{是})} \times \underbrace{0}_{P(\text{正常}|\text{是})} = 0$$

「是」被**一票否决**；而「否」侧 $P(\text{晴}|\text{否})=\frac{1}{3}$，$P(\text{正常}|\text{否})=\frac{2}{3}$，后验 $\propto \frac{3}{5}\times\frac{1}{3}\times\frac{2}{3}=\frac{2}{15}$，只能判「否」，且无法衡量「是」的相对可能性。
天气、湿度各 $V=2$，拉普拉斯修正 $\frac{N_{ic}+1}{N_c+V}$：

概率	未修正	拉普拉斯修正
$P(\text{晴}\|\text{是})$	1	$\frac{2+1}{2+2}=\frac{3}{4}$
$P(\text{正常}\|\text{是})$	0	$\frac{0+1}{2+2}=\frac{1}{4}$
$P(\text{晴}\|\text{否})$	$\frac{1}{3}$	$\frac{1+1}{3+2}=\frac{2}{5}$
$P(\text{正常}\|\text{否})$	$\frac{2}{3}$	$\frac{2+1}{3+2}=\frac{3}{5}$

对 $\mathbf{x}^*=(\text{晴},\text{正常})$：

$$P(\text{是}|\mathbf{x}^*) \propto \frac{2}{5}\times\frac{3}{4}\times\frac{1}{4} = \frac{6}{80} = 0.075$$

$$P(\text{否}|\mathbf{x}^*) \propto \frac{3}{5}\times\frac{2}{5}\times\frac{3}{5} = \frac{18}{125} = 0.144$$

仍判 否（$0.144 > 0.075$），但「是」的后验**不为 0**，可与「否」比较。

方法	$P(\text{是}\mid \text{晴}, \text{正常})$ 相对量	说明
未修正	0	零概率否决整类
拉普拉斯	0.075 vs 否侧 0.144	未出现过的 (晴, 正常) 在「是」类也分到 $\frac{1}{4}$ 等小概率

再例 $\mathbf{x}' = (\text{雨}, \text{高})$：未修正时 $P(\text{雨}|\text{是}) = 0$ 仍否决「是」；修正后 $P(\text{雨}|\text{是}) = \frac{1}{4}$，$P(\text{高}|\text{是}) = \frac{3}{4}$，$P(\text{是}|\mathbf{x}') \propto \frac{2}{5} \times \frac{1}{4} \times \frac{3}{4} = 0.075$，$P(\text{否}|\mathbf{x}') \propto \frac{3}{5} \times \frac{3}{5} \times \frac{2}{5} = \frac{18}{125}$（$P(\text{高}|\text{否}) = \frac{1+1}{5} = \frac{2}{5}$）。

八、连续属性处理

离散属性直接计数；连续属性（身高、体重、年龄等）常用**概率密度**，常设

$$x_i | c \sim \mathcal{N}(\mu_{ic}, \sigma_{ic}^2)$$

$$P(x_i|c) = \frac{1}{\sqrt{2\pi}\sigma_{ic}} \exp\left(-\frac{(x_i - \mu_{ic})^2}{2\sigma_{ic}^2}\right)$$

考试答法：**连续属性通常用高斯分布建模类条件概率**。

九、EM 算法（Expectation-Maximization）（了解）

西瓜书 §7.6 在**高斯混合模型（GMM）**等场景中会用到 EM，用于存在**隐变量 / 未观测变量**时的参数估计。

要解决什么问题?

有些数据**标签或隐类别未知**（如混合分布里每个样本来自哪一个高斯分量），若直接用极大似然，目标函数里既有参数又有“缺失信息”，难以一步求解析解。
EM 思想：交替进行两步，把难优化问题拆成“猜隐变量 → 更新参数”。

两步迭代

步骤	做什么	直观理解
E 步 (Expectation)	固定当前参数，计算隐变量的**后验期望**（“软分配”权重）	每个样本“更像”哪个隐类别?
M 步 (Maximization)	固定 E 步得到的期望，**最大化**对数似然，更新参数	按加权样本重新估计均值、方差、混合系数

反复 **E → M → E → M ...** 直至似然不再明显上升或达到迭代上限。

典型应用

- **GMM 聚类**：隐变量 = 样本属于第 k 个高斯分量的概率；参数 = 各分量均值、协方差、混合权重 π_k
- 含**缺失特征**、**隐类标签**的生成式模型参数学习

与朴素贝叶斯的关系

- **朴素贝叶斯**：类别 c **已知**（监督学习），直接计数或密度估计即可。
- **EM + GMM**：簇标签**未知**（无监督），用 EM 估计“每个点属于各簇的概率”和分布参数。

考试一句话：EM = 有隐变量时，**E 步估期望、M 步极大似然**，交替迭代直至收敛。

十、朴素贝叶斯优缺点

优点：训练快；小样本可用；**文本分类**等高维场景表现好。
缺点：**条件独立假设过强**，概率估计可能不准，但分类边界有时仍可用。

十一、朴素贝叶斯与决策树比较

项目	朴素贝叶斯	决策树
基础思想	概率	规则
训练速度	快	较快
可解释性	一般	强
特征相关性	假设独立	无要求
小样本	较好	一般

十二、考试高频公式汇总

贝叶斯公式

$$P(c|\mathbf{x}) = \frac{P(\mathbf{x}|c)P(c)}{P(\mathbf{x})}$$

决策规则

$$h(\mathbf{x}) = \arg\max_c P(c|\mathbf{x}) = \arg\max_c P(\mathbf{x}|c)P(c)$$

条件独立

$$P(\mathbf{x}|c) = \prod_i P(x_i|c)$$

朴素贝叶斯

$$h(\mathbf{x}) = \arg\max_c P(c) \prod_i P(x_i|c)$$

拉普拉斯修正

$$P(x_i|c) = \frac{N_{ic}+1}{N_c+V}$$

十三、期末考试重点等级

★★★★★（必考）

- 贝叶斯公式
- 先验、后验、类条件概率
- 条件独立假设
- 朴素贝叶斯分类公式
- 拉普拉斯修正

★★★★

- 连续值处理（高斯分布）
- 朴素贝叶斯计算题

★★★

- 贝叶斯决策论
- 优缺点分析
- EM 算法（E 步 / M 步、与 GMM 的关系）

一句话总复习：$P(c|\mathbf{x}) \propto P(c)\prod_i P(x_i|c)$ —— **先验 × 各特征条件概率，谁大判哪类。**

第8章 集成学习

重点：Bagging、Boosting、随机森林（Random Forest）、AdaBoost。

一、什么是集成学习（Ensemble Learning）

核心思想：多个“专家”投票比单个专家更可靠。训练多个学习器 $h_1(x),\dots,h_T(x)$，再综合为 $H(x)$。
目标：将多个**弱学习器**（略好于随机猜测）组合为**强学习器**。

任务	集成形式
分类	$H(\mathbf{x})=\operatorname{sign}\left(\sum_{t=1}^{T} w_t h_t(\mathbf{x})\right)$
回归	$H(\mathbf{x})=\sum_{t=1}^{T} w_t h_t(\mathbf{x})$

二、集成学习成功的条件

西瓜书强调两点（考试常考）：

1. **准确性**：个体学习器应比随机猜测好；
2. **多样性**：学习器不能总犯相同错误。

结论：组合效果好 $\Leftrightarrow$ **准确性** $+$ **多样性**。

三、Bagging（Bootstrap Aggregating）

思想与流程

并行训练 T 个学习器，最后投票/平均。

```
原始训练集 D → Bootstrap 采样得 D'_1…D'_T → 训练 h_1…h_T → 投票/平均
```

Bootstrap 采样（考试必背）

从 $D=\{\mathbf{x}_1,\dots,\mathbf{x}_m\}$ 中**有放回**抽 m 次得 D'：样本可重复、约 **36.8%** 原样本未进入 D'（与第2章自助法一致）：

$$\left(1-\frac{1}{m}\right)^{m}\xrightarrow{m\to\infty}e^{-1}\approx 0.368$$

算法与特点

1. Bootstrap 得到 $D_1, \ldots, D_T$；2. 各训 h_t；3. 分类用**多数投票**，回归用**平均**。

特点	说明
训练	**并行**，互不影响
效果	主要**降低方差**，提高稳定性
过拟合	相对不易

四、随机森林（Random Forest）

定义：Bagging+ 基学习器全部为**决策树**。

双重随机性（考试高频）

1. **样本随机**：Bootstrap，各树数据不同；
2. **特征随机**：每个结点只从 d 个特征中随机抽 k 个（常取 $k = \sqrt{d}$），再在其中选最优划分。

目的：增大树之间差异，提高泛化。
标准表述：随机森林 = Bootstrap 采样 + 随机属性选择。

优缺点

优点：抗过拟合、适合高维、可并行、弱特征选择。缺点：可解释性不如单棵树。

演示例题（$T = 2$ 棵树，便于手算）

训练集（$m = 4$，特征：色泽、根蒂、纹理；标签：好瓜 是/否）：

样本	色泽	根蒂	纹理	好瓜
1	青	蜷缩	清晰	是
2	青	蜷缩	清晰	是
3	赭	蜷缩	清晰	是
4	青	稍蜷	清晰	否

随机性 1：Bootstrap 采样（有放回抽 4 次）

树	抽到的训练子集（编号）	说明
树 1	1, 1, 3, 4	1 重复，2 未出现
树 2	2, 3, 3, 4	3 重复，1 未出现

两棵树训练数据不同 → 学到的划分不同。
随机性 2：结点随机特征（设 $d=3$，取 $k=\lfloor\sqrt{3}\rfloor=1$）
在某结点要分裂时，不看全部 3 个属性，而是**随机抽 1 个**再选最优划分。例如：

- 树 1 某结点抽到「根蒂」→ 可能用「根蒂=蜷缩」划分；
- 树 2 同深度结点抽到「色泽」→ 可能用「色泽=青」划分。

预测新样本 $\mathbf{x}^*=$（青，蜷缩，清晰）：

树	预测
树 1	是
树 2	是

多数投票 → $H(\mathbf{x}^*)=$ **是**。
要点：单棵树可能过拟合某条样本；多棵树因**数据不同 + 分裂特征不同**而“各说各话”，投票后更稳。
实际中 T 常为几十～几百，k 也常取 $\lfloor\log_2 d\rfloor+1$ 等，本题只演示原理。

五、Boosting

与 Bagging 最大区别：**串行**训练，后一轮重点修正前一轮错分样本。

```
弱学习器1 → 提高错分样本权重 → 弱学习器2 → … → 加权组合
```

核心：关注前一轮分错的样本；主要**降低偏差**；比 Bagging **更易过拟合**。

六、AdaBoost（Adaptive Boosting）

Boosting 代表算法，考试最重要。

算法流程

1. 初始化样本权重 $w_i = \dfrac{1}{m}$；
2. 第 t 轮：用当前权重训练 h_t，计算加权错误率
   $\epsilon_t = \sum_i w_i \, \mathbb{I}(h_t(\mathbf{x}_i) \neq y_i)$；
3. 学习器权重（**必背**）：
   $\alpha_t = \dfrac{1}{2} \ln \dfrac{1-\epsilon_t}{\epsilon_t}$（$\epsilon_t$ 越小，α_t 越大）；
4. 更新样本权重：$w_i \leftarrow w_i \cdot e^{-\alpha_t y_i h_t(\mathbf{x}_i)}$（分对权重减、分错权重增）；
5. 重复后得到最终分类器（**必背**）：

$$H(\mathbf{x}) = \operatorname{sign}\left(\sum_{t=1}^{T} \alpha_t h_t(\mathbf{x}) \right)$$

即多个弱学习器**加权投票**组成强学习器。

演示例题（2 轮迭代，一维阈值桩）

5 个样本，特征 $x \in \{1,2,3,4,5\}$，标签 $y \in \{+1,-1\}$：

样本	x	y
1	1	$+1$
2	2	$+1$
3	3	-1
4	4	-1
5	5	$+1$

弱学习器取决策树桩：$h(x) = \operatorname{sign}(x - \theta)$ 的等价规则「$x < 3$ 判 $+1$，否则判 -1」（即 $\theta = 3$）。

第 1 轮

初始化 $w_i = \dfrac{1}{5} = 0.2$。

样本	y	$h_1(x)$	对错	w_i
1–2	$+1$	$+1$	对	0.2
3–4	-1	-1	对	0.2
5	$+1$	-1	错	0.2

加权错误率 $\epsilon_1 = \sum_{i:h_1 \neq y} w_i = 0.2$。

$$\alpha_1 = \frac{1}{2}\ln\frac{1-\epsilon_1}{\epsilon_1} = \frac{1}{2}\ln\frac{0.8}{0.2} = \frac{1}{2}\ln 4 \approx 0.693$$

更新权重 $w_i \leftarrow w_i \cdot e^{-\alpha_1 y_i h_1(x_i)}$：分对乘以 $e^{-0.693} \approx 0.5$，分错乘以 $e^{+0.693} \approx 2$。

样本	更新后（未归一化）	归一化后
1–4	$0.2 \times 0.5 = 0.1$	$0.1/0.8 = 0.125$
5	$0.2 \times 2 = 0.4$	$0.4/0.8 = 0.5$

第 2 轮将重点拟合样本 5（权重从 0.2 升到 0.5）。

第 2 轮（示意）

换弱学习器 h_2，例如「$x \le 1.5$ 判 $+1$，否则判 -1」：专门把样本 5 判对，其余可部分牺牲。设算得 $\epsilon_2 = 0.1$，则 $\alpha_2 = \frac{1}{2}\ln 9 \approx 1.10 > \alpha_1$（更准的弱学习器权重更大）。

最终预测

对测试点 $x = 5$:

$$H(5) = \text{sign}\big(\alpha_1 h_1(5) + \alpha_2 h_2(5) + \cdots\big) = \text{sign}(-0.693 + \cdots)$$

若后续轮次继续提高对 $x=5$ 的“纠正”权重，最终 $\sum_t \alpha_t h_t(5)$ 可翻为正 $\to$ 判 $+1$，与真实标签一致。**本题要记的流程**：初始化权重 $\to$ 训 h_t $\to$ 算 ϵ_t $\to$ 算 α_t $\to$ 更新 w_i $\to$ 加权投票得 $H(x)$。手算时抓住：**错分样本权重变大，下一弱学习器更关注它**。

七、方法对比总表

项目	**Bagging**	**Boosting**	随机森林	**AdaBoost**
训练方式	并行	串行	并行	串行
数据/权重	Bootstrap，权重不变	同集，权重动态	同 Bagging	同 Boosting
关注点	全体样本	错分样本	同 Bagging	错分样本
主要效果	降方差	降偏差	降方差+随机性	降偏差
基学习器	常用决策树等	常用决策树桩	决策树	常用树桩
过拟合	较少	较易	抗过拟合较强	较易
抗噪声	较强	较弱	较强	较弱
可并行	是	否	是	否

一句话：Bagging 靠**多数投票**，Boosting 靠**纠错加权**；随机森林是 Bagging 代表，AdaBoost 是 Boosting 代表。

八、核心公式与考试重点

AdaBoost 学习器权重

$$\alpha_t = \frac{1}{2}\ln\frac{1-\epsilon_t}{\epsilon_t}$$

AdaBoost 最终分类器

$$H(\mathbf{x}) = \text{sign}\left(\sum_{t=1}^{T}\alpha_t h_t(\mathbf{x})\right)$$

Bootstrap 未抽中比例

$$\left(1-\frac{1}{m}\right)^m \approx e^{-1} \approx 0.368$$

★★★★★（必考）

- Bagging / Bootstrap 思想与 36.8%

- Boosting 思想；AdaBoost 流程与两公式
- 随机森林双重随机性
- Bagging 降方差、Boosting 降偏差

★★★★

- 上表对比；随机森林优缺点
- 随机森林 / AdaBoost 演示例题（投票与权重更新）

★★★

- 集成学习准确性+多样性

第9章 聚类

重点：性能度量、原型聚类（K-means）、密度聚类（DBSCAN）、层次聚类（AGNES）。

一、聚类（Clustering）概述

聚类属于**无监督学习**：训练集 $D=\{\mathbf{x}_1,\dots,\mathbf{x}_m\}$ **无类别标签**。
目标：将相似样本划入同一簇（Cluster），使**簇内紧凑、簇间分离**（簇内相似度高，簇间相似度低）。

二、距离与相似度

聚类基础：衡量样本间距离。最常用**欧氏距离**：

$$d(\mathbf{x}_i,\mathbf{x}_j)=\sqrt{\sum_{k=1}^{n}(x_{ik}-x_{jk})^2}$$

闵可夫斯基距离（推广）：

$$d(\mathbf{x},\mathbf{y}) = \left(\sum_i |x_i - y_i|^p \right)^{1/p}$$

p	名称
1	曼哈顿距离
2	欧氏距离
∞	切比雪夫距离 $d = \max_i \lvert x_i - y_i \rvert$

三、聚类性能度量

类型	条件	代表指标
外部指标	已知真实类别	JC、FMI、RI
内部指标	不知真实类别	DB 指数、Dunn 指数

外部指标

把所有样本两两配对，将样本对分为四类：a 同簇同类，b 异簇异类，c 同簇异类，d 异簇同类。

	同类	异类
同簇	a	c
异簇	d	b

$$\mathrm{JC} = \frac{a}{a+c+d}, \quad \mathrm{FMI} = \sqrt{\frac{a}{a+c}\cdot\frac{a}{a+d}}, \quad \mathrm{RI} = \frac{a+b}{a+b+c+d}$$

JC、FMI、RI 均在 $[0,1]$，**越大越好**（RI 越接近 1 越好）。

内部指标

无真实标签时，用簇的**紧凑程度与分离程度**评价。西瓜书常用 **DB 指数**、**Dunn 指数**。
记 k 个簇 $C_1, \dots, C_k$，簇中心 $\boldsymbol{\mu}_i = \frac{1}{|C_i|}\sum_{\mathbf{x}\in C_i}\mathbf{x}$，样本间距离 $d(\cdot,\cdot)$（常用欧氏距离）。

1. DB 指数（Davies-Bouldin Index，DBI）

簇内平均距离（第 i 簇有多"散"）：

$$\bar{d}_i = \frac{1}{|C_i|}\sum_{\mathbf{x}\in C_i} d(\mathbf{x}, \boldsymbol{\mu}_i)$$

簇间中心距离：

$$d_{ij} = d(\boldsymbol{\mu}_i, \boldsymbol{\mu}_j)$$

DB 指数（式 9.12）：

$$\mathrm{DBI} = \frac{1}{k}\sum_{i=1}^{k}\max_{j\neq i}\frac{\bar{d}_i + \bar{d}_j}{d_{ij}}$$

含义：对每个簇 i，找与它"最像"的簇 j（使 $\frac{\bar{d}_i+\bar{d}_j}{d_{ij}}$ 最大），再对所有 i 取平均。分子大 → 簇内松；分母小 → 簇间近；二者都差则 DBI 大。
评价：DBI **越小越好**（簇内紧、簇间远）。

2. Dunn 指数（Dunn Index，DI）

簇间最近距离（两簇最近两个点的距离）：

$$d_{\min}(C_i, C_j) = \min_{\mathbf{x}\in C_i,\,\mathbf{z}\in C_j} d(\mathbf{x}, \mathbf{z})$$

簇直径（簇内最远两点距离，衡量簇有多"胖"）：

$$\mathrm{diam}(C_l) = \max_{\mathbf{x},\mathbf{z}\in C_l} d(\mathbf{x}, \mathbf{z})$$

Dunn 指数（式 9.13）：

$$\mathrm{DI} = \min_{1\le i<j\le k} \frac{d_{\min}(C_i, C_j)}{\max_{1\le l\le k} \operatorname{diam}(C_l)}$$

含义：分子：最近的两簇有多分开；分母：最“胖”的簇有多散。比值大 → 分离好且簇内紧。
评价：DI 越大越好。

对比记忆

指标	关注点	方向
DBI	平均簇内 vs 中心间	越小越好
DI	最近簇间 vs 最大直径	越大越好

考试：公式可能考写法或概念；方向必记。计算题少见，若给 $\bar{d}_i, d_{ij}$ 或 $d_{\min}, \operatorname{diam}$ 可代入上式。

四、三大类聚类方法

类型	代表算法	核心思想
原型聚类	**K-means**	每簇一个中心 $\boldsymbol{\mu}_i$
密度聚类	**DBSCAN**	高密度区域成簇
层次聚类	**AGNES**	自底向上不断合并

五、K-means（原型聚类，考试最重要）

思想

k 个簇中心 $\boldsymbol{\mu}_1, \ldots, \boldsymbol{\mu}_k$；样本归入距离最近的中心所在簇。

流程

随机初始化 k 个中心 → 按距离分配样本 → 更新中心 μ_i = (1/|C_i|)Σ_{x∈C_i}x → 重复至中心不变

优化目标（考试必背）

最小化簇内平方误差（**SSE**）：

$$E = \sum_{i=1}^{k} \sum_{\mathbf{x} \in C_i} \|\mathbf{x} - \boldsymbol{\mu}_i\|^2$$

优缺点

优点	缺点
简单、快	需事先指定 K
易实现	对初始中心敏感，易局部最优
	对噪声敏感，适合凸形/球状簇

六、DBSCAN（密度聚类）

思想：高密度区域形成簇；全称 Density-Based Spatial Clustering。

两个参数

- ε（**Eps**）：邻域半径
- **MinPts**：邻域内最少样本数

三种点（考试必考）

类型	定义
核心点	ε-邻域内样本数 $\geq$ MinPts
边界点	非核心点，但落在某核心点 ε-邻域内
噪声点	既非核心点，也不属任何簇

若 $N_\varepsilon(\mathbf{x})$ 中样本数 $\geq$ MinPts，则 $\mathbf{x}$ **为核心对象**。

聚类过程

从核心对象出发，按**密度直达** $\rightarrow$ **密度可达** $\rightarrow$ **密度相连**扩展成簇。

优缺点

优点	缺点
不需指定簇数	对 ε、MinPts **敏感**
可发现任意形状簇	密度差异大时效果差
能识别噪声点	

七、AGNES（层次聚类）

AGNES（Agglomerative Nesting）：**自底向上**，初始每样本一簇，反复合并**最近**的两簇，直至达到指定 k 或只剩一簇。

簇间距离（合并依据，考试常考）

链接方式	定义	特点
最小（单链接）	$d_{\min}(C_i, C_j) = \min_{\mathbf{x}\in C_i, \mathbf{y}\in C_j} d(\mathbf{x}, \mathbf{y})$	易成链状
最大（全链接）	$d_{\max} = \max d(\mathbf{x}, \mathbf{y})$	簇更紧凑
平均链接	两簇所有样本对距离的平均	最常用

树状图（Dendrogram）

合并过程可画成树状图；**在不同高度切割**得到不同簇数（考试常给图判断）。

八、三种聚类方法对比

方法	K-means	DBSCAN	AGNES
类型	原型聚类	密度聚类	层次聚类
是否需指定簇数	需要	不需要	可指定
任意形状簇	否	是	较好
抗噪声	差	强	一般
速度	快	中	慢
适用	球状簇	任意形状	小中规模

九、核心公式与考试重点

欧氏距离

$$d(\mathbf{x},\mathbf{y})=\sqrt{\sum_i (x_i-y_i)^2}$$

K-means 中心与目标

$$\boldsymbol{\mu}_i=\frac{1}{|C_i|}\sum_{\mathbf{x}\in C_i}\mathbf{x},\quad E=\sum_i\sum_{\mathbf{x}\in C_i}\|\mathbf{x}-\boldsymbol{\mu}_i\|^2$$

外部指标

$$\mathrm{JC}=\frac{a}{a+c+d},\quad \mathrm{FMI}=\sqrt{\frac{a}{a+c}\cdot\frac{a}{a+d}},\quad \mathrm{RI}=\frac{a+b}{a+b+c+d}$$

内部指标

$$\mathrm{DBI}=\frac{1}{k}\sum_{i=1}^{k}\max_{j\neq i}\frac{\bar{d}_i+\bar{d}_j}{d_{ij}},\quad \bar{d}_i=\frac{1}{|C_i|}\sum_{\mathbf{x}\in C_i}d(\mathbf{x},\boldsymbol{\mu}_i)$$

$$\mathrm{DI}=\min_{i<j}\frac{d_{\min}(C_i,C_j)}{\max_l \operatorname{diam}(C_l)}$$

（DBI 越小越好，DI 越大越好。）

★★★★★（必考）

- K-means 流程与目标函数（最小化 SSE）
- DBSCAN：ε、MinPts；核心点 / 边界点 / 噪声点
- AGNES 自底向上流程；三种链接方式
- 三种聚类对比表

★★★★

- JC、FMI、RI；DBI / DI 公式含义与优劣方向

★★★

- 闵可夫斯基距离；树状图切割

速记：K-means = 指定 K + 迭代中心 + $\min\sum\|\mathbf{x}-\boldsymbol{\mu}\|^2$；DBSCAN = ε+MinPts + 密度扩展 + 噪声；AGNES = 逐对合并 + 树状图。

第10章 降维与度量学习

重点：PCA（主成分分析）（概念、推导思路、计算）。度量学习一般了解即可。

一、为什么要降维?

样本 $\mathbf{x} = (x_1, \ldots, x_d)$ 维数 d 很高时的问题:

- **计算量大、存储成本高**
- **维数灾难**:样本稀疏,距离度量失效
- **冗余信息**:如身高(cm)与身高(m)重复

目标:用更少特征表示数据,**维度变少、信息尽量保留**。

二、PCA 核心思想

原始 $\mathbf{x} \in \mathbb{R}^d$,降维后 $\mathbf{z} \in \mathbb{R}^k$($k < d$)。
直观:数据若沿某斜线方向变化最大,该方向信息最多 → 称**第一主成分**;与之垂直的方向变化小,信息少。
数学表述:寻找**投影方向**,使投影后**方差最大**(方差大 → 数据分散 → 信息多)。
主成分 = 协方差矩阵的**特征向量**;重要程度 = 对应**特征值**大小。

三、PCA 数学模型

样本**中心化**后 $X \in \mathbb{R}^{m \times d}$(每行一个样本)。单位向量 $\mathbf{w}$($\|\mathbf{w}\| = 1$),投影 $z_i = \mathbf{w}^T \mathbf{x}_i$。
投影方差:

$$\mathrm{Var}(z) = \mathbf{w}^T S \mathbf{w}$$

其中 **协方差矩阵**(中心化后,考试常考):

$$S = \frac{1}{m} X^T X$$

二维时 $S = \begin{bmatrix} \mathrm{Var}(x_1) & \mathrm{Cov}(x_1, x_2) \\ \mathrm{Cov}(x_1, x_2) & \mathrm{Var}(x_2) \end{bmatrix}$(对角线为方差,非对角为协方差)。
优化目标(考试必背):

$$\max_{\mathbf{w}} \ \mathbf{w}^T S \mathbf{w} \quad \text{s.t.} \quad \mathbf{w}^T \mathbf{w} = 1$$

特征值分解结论

对 S 做 $S\mathbf{v} = \lambda \mathbf{v}$，设 $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_d$，对应特征向量 $\mathbf{v}_1, \ldots, \mathbf{v}_d$：

- **第 i 主成分方向** $= \mathbf{v}_i$（第 i 大特征值对应特征向量）
- **第一主成分** $= \mathbf{v}_1$（最大特征值）

四、PCA 降维步骤（考试高频）

```
1. 中心化：x_i ← x_i − x̄
2. 协方差矩阵：S = (1/m) X^T X
3. 特征值分解：S v = λ v
4. 特征值降序排列
5. 取前 k 个特征向量：W = (v_1,…,v_k)
6. 投影：Z = X W
```

Z 为 $m \times k$ 降维结果（如 2D→1D 即取 $\mathbf{v}_1$ 投影）。

五、贡献率

特征值 λ_i 表示第 i 主方向保留的信息量。
单个主成分贡献率：

$$\frac{\lambda_i}{\sum_j \lambda_j}$$

累计贡献率（选 k 的依据）：

$$\frac{\sum_{i=1}^{k} \lambda_i}{\sum_j \lambda_j}$$

考试常问为何取前 k 个：累计贡献率达到 **85% / 90% / 95%** 等阈值即可。

六、PCA 优缺点

优点	缺点
降维、去冗余、抑噪、提速	线性方法，难刻画非线性结构
	新特征可解释性差（原特征线性组合）
	不可避免丢失部分信息

七、PCA 与 LDA 比较（了解）

项目	PCA	LDA
类型	无监督	有监督
利用标签	否	是
目标	投影方差最大	类间分离最大（Fisher）

八、核心公式与考试重点

$$S = \frac{1}{m} X^T X, \quad \max \mathbf{w}^T S \mathbf{w} \text{ s.t. } \mathbf{w}^T \mathbf{w} = 1, \quad S\mathbf{v} = \lambda \mathbf{v}$$

$$\frac{\lambda_i}{\sum_j \lambda_j}, \quad \frac{\sum_{i=1}^{k} \lambda_i}{\sum_j \lambda_j}, \quad Z = XW$$

★★★★★（必考）

- PCA 思想（最大方差）、协方差矩阵
- 特征值/特征向量与主成分关系
- PCA 六步流程；贡献率与累计贡献率

★★★★

- PCA 优缺点

★★★

- PCA 与 LDA 对比；度量学习概念

一句话：PCA 用**方差最大的方向**作新坐标轴，取前 k 个主成分保留大部分信息，实现 $d \to k$ 降维。
